Projekt końcowy część 9

Aleksandra Goc

2026-04-01

Część 1.

Użyłam danych z przedmiotu statystyka z poprzedniego semestru. Dane pobrałąm ze strony:https://www.ncbi.nlm.nih.gov/ kod do wyszukania badań :GSE101521 Badanie miało na celu analizę genów w grzbietowo-bocznej korze przedczołowej mózgu, które są aktywne podczas myśli samobujczych. Kontrole stanowiły osoby bez myśli samobujczych a badawczą osoby, które doświadczały myśli samobujczych i depresji.

```
base_url <- "https://raw.githubusercontent.com/gocaleksandra5/pd5014_R/main/"

library(readxl)
library(dplyr)

download.file(
  paste0(base_url, "CON%20VS%20MDD.xlsx"),
  destfile = "CON_VS_MDD.xlsx",
  mode = "wb"
)

geny <- read_excel("CON_VS_MDD.xlsx")
```

Struktura danych

```
str(geny)
```

```
## tibble [21,599 x 10] (S3: tbl_df/tbl/data.frame)
##  $ GeneID        : num [1:21599] 6.78e+05 7.51e+05 6.92e+05 1.00e+08 6.43e+04 ...
##  $ padj          : num [1:21599] 0.000175 0.000175 0.000175 0.000175 0.000262 ...
##  $ pvalue        : num [1:21599] 3.60e-08 2.44e-08 4.28e-08 4.57e-08 8.55e-08 2.94e-07 9.23e-07 1.52e
##  $ lfcSE         : num [1:21599] 0.726 0.406 0.441 0.604 0.395 ...
##  $ stat          : num [1:21599] 5.51 5.58 5.48 5.47 5.36 ...
##  $ log2FoldChange: num [1:21599] 4 2.26 2.41 3.3 2.11 2.51 3.32 2.51 3.1 1.37 ...
##  $ baseMean      : num [1:21599] 56.4 77.9 74.7 30.8 55.5 ...
##  $ Symbol        : chr [1:21599] "SNORA26" "CSKMT" "SNORA57" "SNORD115-26" ...
##  $ Description   : chr [1:21599] "small nucleolar RNA, H/ACA box 26" "citrate synthase lysine methyl
##  $ EnsemblGeneID : chr [1:21599] "ENSG00000212588" "ENSG00000214756" "ENSG00000206597" "ENSG00000275
```

Wymiary (wiersze, kolumny)

```r
dim(geny)
```

```
## [1] 21599    10
```

Pierwsze 10 wierszy

```r
head(geny, 10)
```

```
## # A tibble: 10 x 10
##    GeneID    padj  pvalue lfcSE  stat log2FoldChange baseMean Symbol Description
##     <dbl>   <dbl>   <dbl> <dbl> <dbl>          <dbl>    <dbl> <chr>  <chr>
##  1 6.78e5 1.75e-4 3.60e-8 0.726  5.51           4        56.4 SNORA~ small nucl~
##  2 7.51e5 1.75e-4 2.44e-8 0.406  5.58           2.26     77.9 CSKMT  citrate sy~
##  3 6.92e5 1.75e-4 4.28e-8 0.440  5.48           2.41     74.7 SNORA~ small nucl~
##  4 1.00e8 1.75e-4 4.57e-8 0.604  5.47           3.3      30.8 SNORD~ small nucl~
##  5 6.43e4 2.62e-4 8.55e-8 0.394  5.36           2.11     55.5 HIF3A  hypoxia in~
##  6 8.43e4 7.52e-4 2.94e-7 0.489  5.13           2.51    113.  TMEM1~ transmembr~
##  7 2.68e4 2.02e-3 9.23e-7 0.677  4.91           3.32     22.8 SNORD~ small nucl~
##  8 6.78e5 2.59e-3 1.52e-6 0.522  4.81           2.51     28.0 SNORA~ small nucl~
##  9 1.07e8 2.59e-3 1.52e-6 0.644  4.81           3.1      19.4 MIR36~ MIR3677 an~
## 10 4.85e3 3.39e-3 2.21e-6 0.290  4.73           1.37    146.  NOTCH1 notch rece~
## # i 1 more variable: EnsemblGeneID <chr>
```

```r
tail(geny, 5)
```

Ostatnie 5 wierszy

```
## # A tibble: 5 x 10
##      GeneID  padj pvalue lfcSE   stat log2FoldChange baseMean Symbol Description
##       <dbl> <dbl>  <dbl> <dbl>  <dbl>          <dbl>    <dbl> <chr>  <chr>
## 1 101929819    NA 0.571  0.343 -0.567         -0.194     5.10 LOC10~ putative u~
## 2 107987398    NA 0.669  0.340  0.428          0.145     1.61 LOC10~ replaced b~
## 3 105379566    NA 0.0224 0.379  2.28           0.865     2.36 LOC10~ endogenous~
## 4 101927088    NA 0.0171 0.427  2.38           1.02      2.31 LOC10~ uncharacte~
## 5 100233156    NA 0.0804 0.451  1.75           0.789     4.41 LOC10~ tektin 4 p~
## # i 1 more variable: EnsemblGeneID <chr>
```

Część 2.

Sprawdzenie NA

```r
colSums(is.na(geny))
```

```
##         GeneID           padj         pvalue          lfcSE           stat
##              0           6282              0              0              0
## log2FoldChange       baseMean         Symbol    Description  EnsemblGeneID
##              0              0              0            510           3754
```

Dodanie przykładowych NA (są w pliku, ale nie byłam pewna czy i tak nie trzeba dodać NA w ramach zadania)

```
geny[1, 1] <- NA
geny[1, 2] <- NA
geny[1, 3] <- NA
```

Usunięcie NA

```
geny_BEZ_NA <- na.omit(geny)
```

Tabela bez NA

```
colSums(is.na(geny_BEZ_NA))
```

```
##         GeneID           padj         pvalue          lfcSE           stat
##              0              0              0              0              0
## log2FoldChange       baseMean         Symbol    Description  EnsemblGeneID
##              0              0              0              0              0
```

Przekształcenie danych na factor

```
geny_BEZ_NA$Symbol <- as.factor(geny_BEZ_NA$Symbol)
```

Duże litery

```
colnames(geny_BEZ_NA) <- toupper(colnames(geny_BEZ_NA))
```

Sortowanie LOG2FOLDCHANGE

```
geny_posortowane <- geny_BEZ_NA[order(-geny_BEZ_NA$LOG2FOLDCHANGE), ]
```

Tylko warośći większe od >0,05 czyli statystycznie mające znaczenie

```r
geny_przefiltrowane <- geny_posortowane[geny_posortowane$PVALUE > 0.05, ]
head(geny_przefiltrowane)
```

```
## # A tibble: 6 x 10
##   GENEID  PADJ PVALUE LFCSE  STAT LOG2FOLDCHANGE BASEMEAN SYMBOL   DESCRIPTION
##    <dbl> <dbl>  <dbl> <dbl> <dbl>          <dbl>    <dbl> <fct>    <chr>
## 1  26787 0.879 0.0601  1.23  1.88           2.31     882. SNORD61  small nucleo~
## 2 574457 0.879 0.09    1.20  1.70           2.04    2324. MIR181D  microRNA 181d
## 3 407003 0.879 0.0682  1.11  1.82           2.03    2356. MIR219A2 microRNA 219~
## 4  26801 0.879 0.0548  1.04  1.92           1.99    1627. SNORD48  small nucleo~
## 5 406892 0.879 0.185   1.47  1.33           1.94   18877. MIR100   microRNA 100
## 6  26809 0.879 0.099   1.17  1.65           1.94     962. SNORD42A small nucleo~
## # i 1 more variable: ENSEMBLGENEID <chr>
```

Część 3

Sprawdzenie braków

```r
colSums(is.na(geny))
```

```
##         GeneID           padj         pvalue          lfcSE           stat
##              1           6283              1              0              0
## log2FoldChange       baseMean         Symbol    Description  EnsemblGeneID
##              0              0              0            510           3754
```

Zamiana NA na średnią

```r
geny_srednie <- geny
num_cols <- sapply(geny_srednie, is.numeric)
geny_srednie[num_cols] <- lapply(geny_srednie[num_cols], function(x) {
  x[is.na(x)] <- mean(x, na.rm = TRUE)
  return(x)
})

head(geny_srednie)
```

```
## # A tibble: 6 x 10
##    GeneID    padj  pvalue lfcSE  stat log2FoldChange baseMean Symbol Description
##     <dbl>   <dbl>   <dbl> <dbl> <dbl>          <dbl>    <dbl> <chr>  <chr>
## 1  2.38e7 9.01e-1 4.89e-1 0.726  5.51           4        56.4 SNORA~ small nucl~
## 2  7.51e5 1.75e-4 2.44e-8 0.406  5.58           2.26     77.9 CSKMT  citrate sy~
## 3  6.92e5 1.75e-4 4.28e-8 0.440  5.48           2.41     74.7 SNORA~ small nucl~
## 4  1.00e8 1.75e-4 4.57e-8 0.604  5.47           3.3      30.8 SNORD~ small nucl~
## 5  6.43e4 2.62e-4 8.55e-8 0.394  5.36           2.11     55.5 HIF3A  hypoxia in~
## 6  8.43e4 7.52e-4 2.94e-7 0.489  5.13           2.51    113.  TMEM1~ transmembr~
## # i 1 more variable: EnsemblGeneID <chr>
```

Część 4

Filtrowanie

```
filtered <- geny_srednie %>%
  filter(padj < 0.05)
```

Wybór kolumn

```
selected <- geny_srednie %>%
  select(GeneID, log2FoldChange, baseMean)
```

Modyfikacja

```
modified <- geny_srednie %>%
  mutate(high_expression = baseMean > mean(baseMean))
```

Suma

```
sorted <- geny_srednie %>%
  arrange(desc(log2FoldChange))

geny_srednie %>%
  summarise(
    srednia = mean(log2FoldChange),
    odchylenie = sd(log2FoldChange),
    minimum = min(log2FoldChange),
    maksimum = max(log2FoldChange)
  )
```

```
## # A tibble: 1 x 4
##   srednia odchylenie minimum maksimum
##     <dbl>      <dbl>   <dbl>    <dbl>
## 1 -0.0127      0.366   -2.41        4
```

Część 5

Statystyki

```
summary(geny_srednie)
```

```
##      GeneID                padj              pvalue           lfcSE
##  Min.   :        1   Min.   :0.000175   Min.   :0.0000   Min.   :0.0855
##  1st Qu.:     9738   1st Qu.:0.878619   1st Qu.:0.2460   1st Qu.:0.2038
```

```
##  Median :    79184   Median :0.900555   Median :0.4790   Median :0.2474
##  Mean   : 23812365   Mean   :0.900555   Mean   :0.4889   Mean   :0.2761
##  3rd Qu.:   644962   3rd Qu.:0.920244   3rd Qu.:0.7320   3rd Qu.:0.2996
##  Max.   :115308161   Max.   :0.999943   Max.   :1.0000   Max.   :2.5016
##       stat         log2FoldChange        baseMean            Symbol
##  Min.   :-3.3033   Min.   :-2.41000   Min.   :     0.88   Length:21599
##  1st Qu.:-0.8739   1st Qu.:-0.20900   1st Qu.:     5.64   Class :character
##  Median :-0.2565   Median :-0.05880   Median :    23.28   Mode  :character
##  Mean   :-0.1559   Mean   :-0.01272   Mean   :   338.48
##  3rd Qu.: 0.4764   3rd Qu.: 0.11200   3rd Qu.:    78.22
##  Max.   : 5.5776   Max.   : 4.00000   Max.   :208121.21
##  Description        EnsemblGeneID
##  Length:21599       Length:21599
##  Class :character   Class :character
##  Mode  :character   Mode  :character
##
##
##
```

```r
num_cols <- sapply(geny_srednie, is.numeric)

statystyki <- data.frame(
  min = sapply(geny_srednie[num_cols], min),
  max = sapply(geny_srednie[num_cols], max),
  mean = sapply(geny_srednie[num_cols], mean),
  median = sapply(geny_srednie[num_cols], median),
  sd = sapply(geny_srednie[num_cols], sd)
)

statystyki
```

```
##                          min          max          mean        median
## GeneID          1.0000000000 1.153082e+08  2.381237e+07 79184.0000000
## padj            0.0001750000 9.999430e-01  9.005552e-01     0.9005552
## pvalue          0.0000000244 1.000000e+00  4.888754e-01     0.4790000
## lfcSE           0.0855000000 2.501600e+00  2.760751e-01     0.2474000
## stat           -3.3032640200 5.577592e+00 -1.558559e-01    -0.2564809
## log2FoldChange -2.4100000000 4.000000e+00 -1.271532e-02    -0.0588000
## baseMean        0.8770000000 2.081212e+05  3.384770e+02    23.2850000
##                          sd
## GeneID         4.369437e+07
## padj           7.484107e-02
## pvalue         2.832635e-01
## lfcSE          1.785172e-01
## stat           1.006109e+00
## log2FoldChange 3.660230e-01
## baseMean       3.863056e+03
```

Część 6.

T-student

Żeby porównać dwie grupy, pobrałam kolejną grupę: kontrolę vs. osoby po próbach samobójczych. Pierwszy plik zawierał grupy: kontrola vs. osoby z depresją. W tych plikach nie było jednak danych odpowiednich do przeprowadzenia testu t-Studenta, więc dodałam kolumnę o nazwie „poziom ekspresji genów" i wygenerowałam losowe liczby.

```r
library(dplyr)

download.file(
  paste0(base_url, "CON%20VS%20MDD-S.xlsx"),
  destfile = "CON_VS_MDD-S.xlsx",
  mode = "wb"
)


geny.nr.2 <- read_excel("CON_VS_MDD-S.xlsx", na = "NA")
geny <- geny %>%
  mutate('Poziom ekspresji genów' =
           runif(n()))
geny.nr.2 <- geny %>%
  mutate('Poziom ekspresji genów' =
           runif(n()))

x <- geny$`Poziom ekspresji genów`
y <- geny.nr.2$`Poziom ekspresji genów`
t.test(x, y)
```

```
##
##  Welch Two Sample t-test
##
## data:  x and y
## t = -0.72888, df = 43196, p-value = 0.4661
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
##  -0.007470058  0.003420238
## sample estimates:
## mean of x mean of y
## 0.5009413 0.5029662
```

```r
#Ze względu, że liczby są generowane losowo wstawiam przykłądwe moje wyniki, które wyjaśniam:

#t = 0.32365, df = 43195, p-value = 0.7462
#alternative hypothesis: true difference in means is not equal to 0
#95 percent confidence interval:
#  -0.004545716  0.006343856
#sample estimates:
#  mean of x mean of y
#0.5016605 0.5007615

#p-value oznacza że u mnie brak jest istostnej różnicy między grupami
```

```r
#różnica średnich jest minimalna
#przedział ufności 95% potwierdza brak istotności
```

Część 7.

Wykresy

```r
library(ggplot2)
library(dplyr)

geny_srednie <- geny_srednie %>%
  mutate(group = ifelse(log2FoldChange > 2, "high", "low"))

posortowane <- geny_srednie %>%
  arrange(desc(log2FoldChange))
```

Histogram

```r
ggplot(geny_srednie, aes(x = log2FoldChange)) +
  geom_histogram(fill = "pink", bins = 30) +
  labs(title = "Rozkład log2FoldChange")
```

```
## Warning in grid.Call(C_textBounds, as.graphicsAnnot(x$label), x$x, x$y, :
## conversion failure on 'Rozkład log2FoldChange' in 'mbcsToSbcs': dot substituted
## for <c5>

## Warning in grid.Call(C_textBounds, as.graphicsAnnot(x$label), x$x, x$y, :
## conversion failure on 'Rozkład log2FoldChange' in 'mbcsToSbcs': dot substituted
## for <82>

## Warning in grid.Call.graphics(C_text, as.graphicsAnnot(x$label), x$x, x$y, :
## conversion failure on 'Rozkład log2FoldChange' in 'mbcsToSbcs': dot substituted
## for <c5>

## Warning in grid.Call.graphics(C_text, as.graphicsAnnot(x$label), x$x, x$y, :
## conversion failure on 'Rozkład log2FoldChange' in 'mbcsToSbcs': dot substituted
## for <82>
```

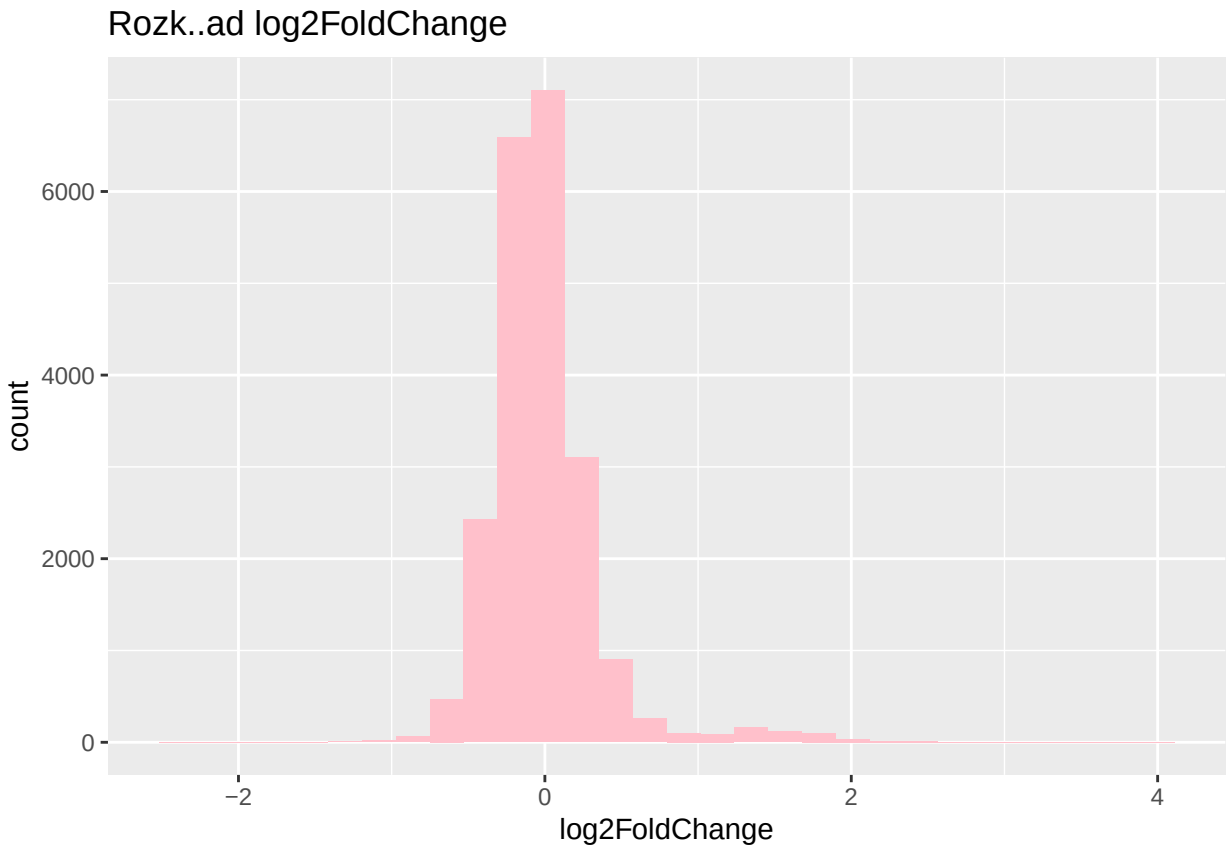

Wykres pudełkowy

```
ggplot(geny_srednie, aes(x = group, y = log2FoldChange)) +
  geom_boxplot(fill = "pink") +
  labs(title = "Porównanie grup")
```

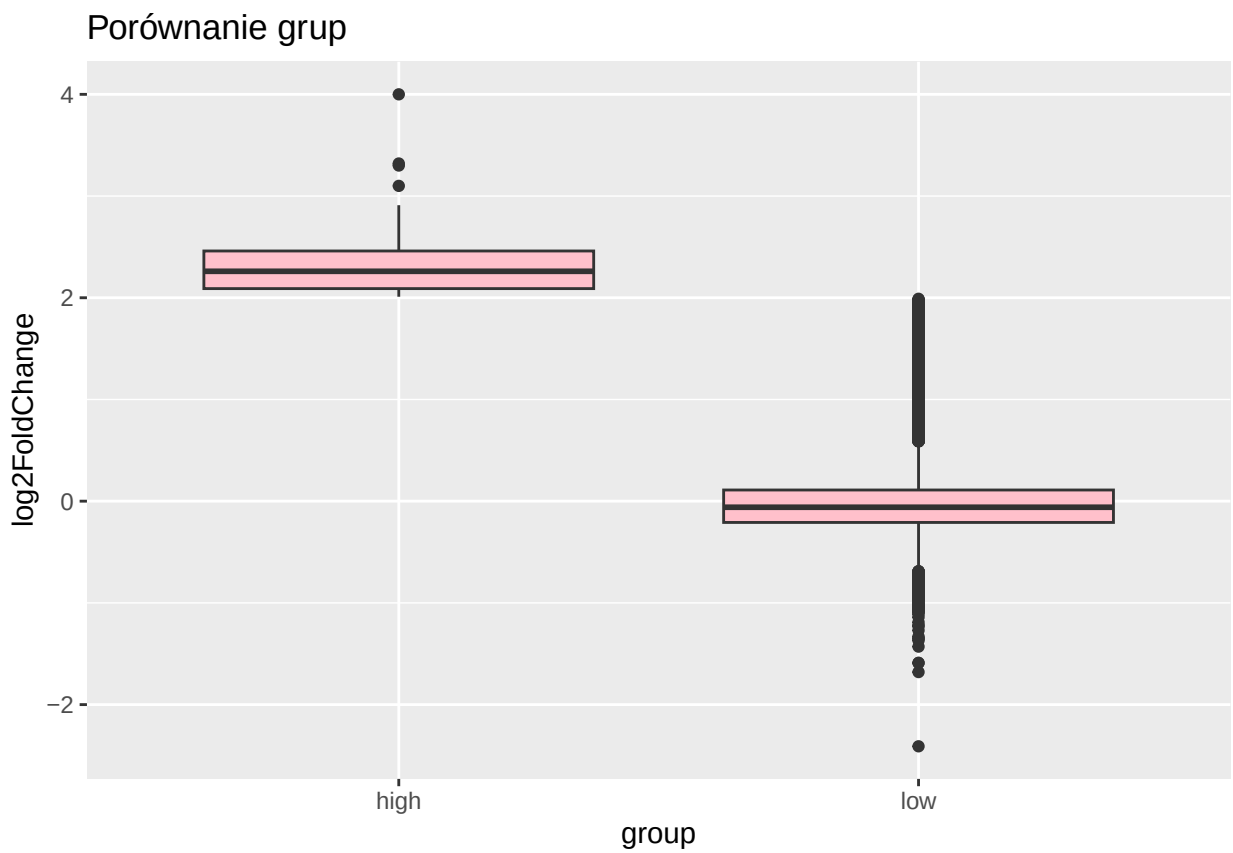

Wykres liniowy

```
ggplot(head(posortowane, 20),
       aes(x = reorder(Symbol, log2FoldChange),
           y = log2FoldChange,
           group = 1)) +
  geom_line() +
  geom_point() +
  theme(axis.text.x = element_text(angle = 90)) +
  labs(title = "Top 20 genów")
```

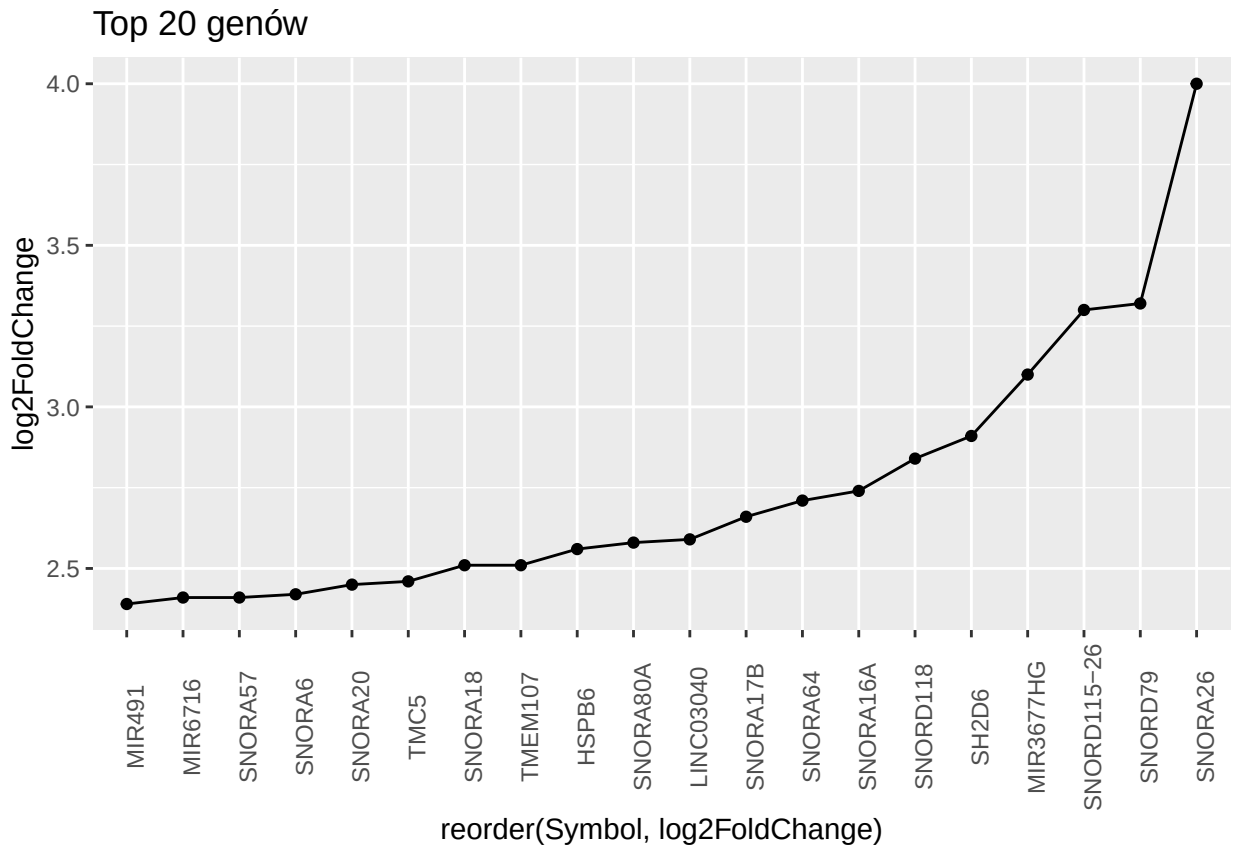

Część nr.8

Zrobłam fukcje, która sortuje po istotności 0.05

```
filter_genes <- function(geny, padj_threshold = 0.05, lfc_threshold = 1) {

  filtered <- geny[
    !is.na(geny$padj) &
      geny$padj < padj_threshold &
      abs(geny$log2FoldChange) > lfc_threshold,
  ]
  filtered <- filtered[order(filtered$padj), ]

  return(filtered)
}

geny_filtered <- filter_genes(geny)

head(geny_filtered)
```

```
## # A tibble: 6 x 11
##    GeneID    padj  pvalue lfcSE  stat log2FoldChange baseMean Symbol Description
##     <dbl>   <dbl>   <dbl> <dbl> <dbl>          <dbl>    <dbl> <chr>  <chr>
```

```
## 1  7.51e5 1.75e-4 2.44e-8 0.406  5.58          2.26     77.9 CSKMT  citrate sy~
## 2  6.92e5 1.75e-4 4.28e-8 0.440  5.48          2.41     74.7 SNORA~ small nucl~
## 3  1.00e8 1.75e-4 4.57e-8 0.604  5.47          3.3      30.8 SNORD~ small nucl~
## 4  6.43e4 2.62e-4 8.55e-8 0.394  5.36          2.11     55.5 HIF3A  hypoxia in~
## 5  8.43e4 7.52e-4 2.94e-7 0.489  5.13          2.51    113.  TMEM1~ transmembr~
## 6  2.68e4 2.02e-3 9.23e-7 0.677  4.91          3.32     22.8 SNORD~ small nucl~
## # i 2 more variables: EnsemblGeneID <chr>, ‘Poziom ekspresji genów‘ <dbl>
```